

Projekt IO.1: Klasyfikacja ceny pojazdów.

m.kurowski.023

May 2024

Spis treści

1	Wstęp	2
2	Baza danych	3
3	Preprocessing	4
3.1	Usuwanie zbędnych danych	4
3.2	Usuwanie nieprawidłowych lub odstających danych	4
3.3	Uzupełnianie brakujących danych	5
3.4	Ujednolicenie typów	5
3.5	Własnoręczna klasyfikacja	6
3.5.1	Dziesięcioklasowa	6
3.5.2	Dwuklasowa	6
3.6	Normalizacja	8
3.7	PCA	8
4	Proste klasyfikatory	12
4.1	K-najbliższych sąsiadów (K-Nearest Neighbors - KNN)	12
4.1.1	Wyniki	12
4.2	Wykresy	12
4.3	Naiwny Bayes (Naive Bayes)	17
4.3.1	GaussianNB	17
4.3.2	CategoricalNB	19
4.3.3	MultinomialNB	21
4.3.4	BernoulliNB	23
4.3.5	ComplementNB	25
5	Reguły asocjacyjne	27
6	MLP	27
6.1	Wyniki	29
6.1.1	Model dwuklasowy	29
6.1.2	Model dziesięcioklasowy	31

7 Bibliografia	33
8 Zakończenie	33

1 Wstęp

Samochodami pasjonuję się od kiedy pamiętam, moim pierwszym pomysłem na realizację projektu było rozpoznawanie samochodów ze zdjęć, ale stwierdziłem, że ten pomysł może zrealizuję jako drugi projekt, więc naturalnie jako temat projektu nr.1 przyjąłem klasyfikację cenową pojazdów samochodowych, gdyż wycena auta to naturalny problem występujący przy sprzedaży.

Więc, jak poradziły sobie z tym problemem podstawowe klasyfikatory oraz sieć?

2 Baza danych

Pierwotna baza danych składa się z 426 880 rekordów oraz 26 kolumn:

- id
- url
- region
- region_url
- price
- year
- manufacturer
- model
- condition
- cylinders
- fuel
- odometer
- title_status
- transmission
- VIN
- drive
- size
- type
- paint_color
- image_url
- description
- county
- state
- lat
- long
- posting_date

3 Preprocessing

3.1 Usuwanie zbędnych danych

Postanowiłem usunąć ze zbioru danych kolumny, które nie miały większego znaczenia dla predykcji lub dane nieprzydatne, jak description, które raczej się nie powtarza, jego istnienie nie ma sensu w datasetcie bez tokenizacji, której jeszcze nie umiem. Lista usuniętych kolumn:

- id
- url
- region_url
- VIN
- image_url
- description
- state
- lat
- long
- posting_date
- title_status
- region

3.2 Usuwanie nieprawidłowych lub odstających danych

Dla poprawienia efektywności postanowiłem również usunąć rekordy z nieprawidłowymi danymi gdzie:

- Cena jest równa 0 lub większa niż 5 milionów USD
- Rok produkcji jest większy niż 2024 lub mniejszy niż 1900

W wyniku preprocessingu liczba rekordów zmniejszyła się o około 10%, do 382558 rekordów

3.3 Uzupełnianie brakujących danych

Ze względu na to, iż w zdecydowanej większości rekordów w co najmniej jednej kolumnie znajdowało się "N/A" postanowiłem uzupełnić dane za pomocą imputacji:

- Braki w kolumnach numerycznych uzupełnić medianą z kolumny
- Braki w kolumnach kategoryalnych uzupełnić najczęściej występującą wartością

Kod:

```
def fill_na(df: DataFrame) -> DataFrame:
    new_df = df.copy()
    cat_cols, num_cols = return_categorical_and_numerical_cols(df)

    numerical_imputer = SimpleImputer(strategy="median")
    categorical_imputer = SimpleImputer(strategy="most_frequent")

    # Uzupełnij brakujące wartości w danych numerycznych medianą
    new_df[num_cols] = numerical_imputer.fit_transform(df[num_cols])

    # Uzupełnij brakujące wartości w danych kategorycznych
    # najczęściej występującą wartością
    new_df[cat_cols] = categorical_imputer.fit_transform(df[cat_cols])
    return new_df
```

3.4 Ujednolicenie typów

Następnym moim krokiem było ujednolicenie typów kolumn typu numerycznego i sprowadzenie ich wszystkich typów do typu int.

```
def fix_types(df: DataFrame) -> DataFrame:
    new_df = df.copy()
    new_df["year"] = new_df["year"].astype(int)
    new_df["odometer"] = new_df["odometer"].astype(int)
    new_df["price"] = new_df["price"].astype(int)
    return new_df
```

3.5 Własnoręczna klasyfikacja

3.5.1 Dziesięcioklasowa

Ponadto, by uniknąć korzystania z modeli regresyjnych, które nie były używane na zajęciach, postanowiłem własnoręcznie sklasyfikować wartości kolumny "prices" przez wygenerowanie 10 mniej więcej równych (wg. kwartyli) przedziałów cenowych, do których zostały przydzielone poszczególne rekordy.

```
def get_intervals(df: DataFrame) -> list[tuple[int, int]]:
    X = df["price"] # Column of data
    num_intervals = 10 # Number of intervals
    intervals = qcut(X, q=num_intervals)
    my_intervals = []
    # Retrieving the right side of each interval
    for interval in intervals.unique():
        my_intervals.append((interval.left, interval.right))
    my_intervals.sort() # Sorting the intervals
    return my_intervals

def get_class(price: int, intervals: list[tuple[int, int]]) -> str:
    for left, right in intervals:
        if price < right:
            left_k = round(left / 1000, 1)
            right_k = round(right / 1000, 1)
            return f"({left_k}k, {right_k}k)"
    # If price is greater than all intervals, return the last interval
    last = round(intervals[-1][1] / 1000, 1)
    return f"({last}k+)"

def set_classes(df: DataFrame) -> DataFrame:
    new_df = df.copy()
    intervals = get_intervals(new_df) # Get intervals from new_df
    new_df["price"] = new_df["price"].apply(get_class, intervals=intervals)
    return new_df
```

3.5.2 Dwuklasowa

Dla celów eksperymentalnych, postanowiłem również spróbować klasyfikacji na zbiorze, gdzie przewidywana jest cena w zakresie: "cheap" lub "expensive".

```
def set_easy_classes(df: DataFrame) -> DataFrame:
    median = df["price"].median() # Calculate the median price
    # Use the apply method to generate labels based on the median price
    df["price"] = df["price"].apply(lambda x: "expensive" if x > median else "cheap")
```

```
return df
```

3.6 Normalizacja

Wszystkie kolumny tekstowe oprócz prices, postanowiłem znormalizować za pomocą LabelEncoder'a. Natomiast wszystkie kolumny numeryczne zostały przeze mnie przeskalowane MinMaxScaler'em.

```
def normalize(df: DataFrame) -> DataFrame:
    cat_cols, num_cols = return_categorical_and_numerical_cols(df)
    price_index = np.where(cat_cols == "price")
    cat_cols = cat_cols.delete(price_index)
    # Wykonaj kodowanie kategoriycznych danych za pomoc LabelEncoder
    label_encoder = LabelEncoder()
    for col in cat_cols:
        df[col] = label_encoder.fit_transform(df[col])

    # Wykonaj skalowanie danych numerycznych za pomoc MinMaxScaler
    scaler = MinMaxScaler()
    df[num_cols] = scaler.fit_transform(df[num_cols])


    return df
```

3.7 PCA

Postanowiłem przeprowadzić analizę PCA dla danych przed usunięciem oraz po usunięciu kolumn, przy zachowaniu wszystkich kroków preprossingu oraz normalizacji.

Wyniki analizy przed usunięciem kolumn:

Jak widać na powyższym wykresie przynajmniej 2 komponenty można usunąć, ponieważ nie przynoszą większego sensu dla zróżnicowania danych.




Rysunek 1: PCA przed

Wyniki analizy po usunięciu kolumn: Wyniki wskazują na to, iż usunięcie,

F1	F2	F3	F5	F6
0.9999973975525233	0.9999999781682694	0.9999999920745544	0.9999999998751801	1.0

którejkolwiek z kolumn nie przyniosłoby większych korzyści, a oznaczałoby dużą stratę danych.

Po przeprowadzeniu wszystkich elementów preprocessingu, wyniki analizy PCA dla wszystkich pozostałych (6) kolumn prezentują się następująco:



Rysunek 2: PCA po

4 Proste klasyfikatory

Wszystkie klasyfikatory były wielokrotnie przeze mnie testowane na zbiorze testowym różnej wielkości przy podziale 80% - zbiór treningowy oraz 20% - zbiór testowy

4.1 K-najbliższych sąsiadów (K-Nearest Neighbors - KNN)


Klasyfikator KNN postanowiłem przetestować dla k równego każdej liczbie nieparzystej od 1 do 29.

4.1.1 Wyniki


k	Accuracy
1	71.1%
3	65.9%
5	63.7%
7	61.7%
9	60.1%

4.2 Wykresy


Jak widać na poniższych wykresach oraz na podstawie powyższej tabeli, można wyciągnąć wnioski, iż dane mogą być na tyle skorelowane, że z każdym kolejnym k dokładność spada.




Rysunek 3: Wyniki dla poszczególnych wartości k.



Rysunek 4: Macierz błędów dla $k = 1$



Rysunek 5: Macierz błędów dla $k = 3$




Rysunek 6: Macierz błędów dla k = 5

4.3 Naiwny Bayes (Naive Bayes)

Dla celów eksperymentu, na zbiorze danych postanowiłem przetestować następujące klasyfikatory:

4.3.1 GaussianNB


GaussianNB na zbiorze testowym osiągnął dość mierny wynik 17% co może sugerować, iż features nie są zbyt skorelowane, a ich rozkład można opisać jako rozkład normalny.



Rysunek 7: Macierz błędów dla GaussianNB

4.3.2 CategoricalNB


Ten klasyfikator osiągnął wynik 38% co oznacza, iż najlepiej sobie poradził ze zbiorem testowym ze wszystkich przetestowanych przeze mnie klasyfikatorów NB. Jego wyższa dokładność w porównaniu do innych klasyfikatorów typu NB może wynikać z wielomianowego rozkładu danych. Jest dobry dla wartości z zakodowanymi kategoriami.



Rysunek 8: Macierz błędów dla CategoricalNB

4.3.3 MultinomialNB


MultinomialNB jest podobny do CategoricalNB, ale jest bardziej ogólny, gdy chodzi o dane z cechami, które mogą być zliczane, takimi jak liczebność słów w dokumentach (np. w analizie tekstu). Ten klasyfikator jest często używany do klasyfikacji dokumentów tekstowych. W moim przypadku znormalizowane dane nie wykazują cech, które predysponowałyby użycie tego klasyfikatora. Stąd też jego wynik w postaci 14%.



Rysunek 9: Macierz błędów dla MultinomialNB

4.3.4 BernoulliNB

Ten klasyfikator jest używany, gdy dane wejściowe są binarne (takie jak wystąpienie lub nie wystąpienie danej cechy). Przykłady to dane uzyskane przez binarne kodowanie, takie jak obrazy binarne lub analiza sentymentu. Biorąc pod uwagę ilość klas w moim zbiorze danych, czyli 10, ten klasyfikator względnie poradził sobie z rozróżnieniem 3 klas, lecz w większości predyktowane były dane z jednej klasy, czego rezultatem był wynik 16% dokładności.




Rysunek 10: Macierz błędów dla BernoulliNB

4.3.5 ComplementNB

Ten klasyfikator jest wariantem MultinomialNB, który jest lepiej dostosowany do danych niezrównoważonych, gdzie jedna klasa jest bardziej liczna niż pozostałe. ComplementNB przeciwdziała problemowi związane z nierównomierną liczbą próbek klas poprzez obliczanie wag dla każdej klasy na podstawie jej częstości w danych treningowych.

W moim zbiorze danych wszystkie klasy są mniej więcej zrównoważone. W zbiorze testowym średnio przypada po 4000 przypadków każdej klasy, co stawia ten klasyfikator na przegranej pozycji z wynikiem zaledwie 14% dokładności.



Rysunek 11: Macierz błędów dla ComplementNB

5 Reguły asocjacyjne

Zdecydowana większość reguł potwierdzonych dużym wsparciem, dotyczy głównie roczników z przedziału 2001-2020, co nie wydaje się zbyt interesujące, bardziej konkretne i sensowne reguły chciałbym przedstawić poniżej.

Antecedents	Consequents	support	confidence	Lift
(price_ (0.5k , 4.2k>)	fuel_gas	0.094556	0.959064	1.136254
fuel_diesel	transmission_automatic	0.059554	0.880196	1.127777
transmission_automatic	fuel_gas	0.684027	0.876430	1.038353
transmission_manual	fuel_gas	0.053683	0.883084	1.046237
odometer_ <100k, 200k)	year_2001-2020	0.342249	0.926820	1.003494
odometer_ <100k, 200k)	transmission_automatic	0.341763	0.925503	1.185828

6 MLP

By dobrać odpowiednie parametry optymalnego modelu MLP postanowiłem skorzystać z GridSearchCV, który przetestował za mnie 112 permutacji modelu i wytypował najlepszy wariant. Parametry GridSearchCV:

- solvery: adam, SGD
- learning_rate_init: 0.01, 0.001
- hidden_layer_sizes: (6), (6,12),(6,12,2), // dla 10 klas (6,10)
- funkcje aktywacji: relu, tanh
- batch_size: [32,64,128]
- learning_rate: constant, adaptive

Niestety, z nieznanymi mi dokładnie przyczyn, sieć okazała się nieporadzić z danymi w formacie 10 klas i w najlepszym wariancie osiągnęła dokładność rzędu 11%. Aczkolwiek może to wynikać z:

- Braku większych różnic między rekordami
- Możliwe, że dane są odpowiednie, lecz model potrzebowałby liczby iteracji, czy też o wiele większych warstw, których siłą rzeczy nie jestem w stanie sprawdzić.

Z tego powodu stwierdziłem, iż ponownie skategoryzuję dane, tym razem określając cenę każdego pojazdu jako "expensive" jeśli jego cena jest powyżej mediany oraz "cheap" w przeciwnym wypadku. Tym sposobem nowy dataset można określić jako binarny.

Taka sama konfiguracja GridSearchCV przyniosła tym razem: 50% dokładności, co przy 5 razy mniejszej ilości klas daje niemalże taki sam wynik. Niestety,

wszelkie konfiguracje modelu jakie testowałem nie przynosiły znaczących rezultatów. Dość spora maksymalna ilość iteracji - 3000, w mojej opinii mogła nie wystarczyć do skutecznego wytrenowania modelu, ponieważ wciąż dostawałem errorry:


```
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (3000) reached
```

Co sugeruje, iż należałoby zwiększyć liczbę maksymalnych iteracji, co też uczyniłem i zarówno przy liczbie 3000 jak i 5000, uczenie nie dobiegało końca. Uczenie trwało kilkakrotnie dłużej i zazwyczaj kończyło się zawieszeniem systemu.


6.1 Wyniki

% danych	il. klas	ativation	learning_rate_init	hidden_layer_sizes	solver	max_iter	batch_size	accuracy
10	10	relu	0.01	(6,)	adam	200	64	11%
10	10	tanh	0.01	(6,)	sgd	200	64	10%
10	2	relu	0.01	(6,)	adam	200	64	49%
10	2	tanh	0.01	(6,)	sgd	3000	128	50%
10	2	tanh	0.01	(6,)	sgd	200	64	50%
10	2	tanh	0.01	(6, 12)	adam	3000	128	50%

6.1.1 Model dwuklasowy




Rysunek 12: Krzywa uczenia się




Rysunek 13: Macierz błędów

6.1.2 Model dziesięcioklasowy



Rysunek 14: Krzywa uczenia się



Rysunek 15: Macierz błędów

7 Bibliografia

- Dataset: <https://www.kaggle.com/datasets/austinreese/craigslist-carstrucks-data>
- Tutoriale:
 - <https://www.datacamp.com/tutorial/k-nearest-neighbor-classification-scikit-learn>
 - <https://www.datacamp.com/tutorial/k-nearest-neighbor-classification-scikit-learn>
- Dokumentacja: <https://scikit-learn.org/stable/>
- ChatGPT: <https://chatgpt.com/>

8 Zakończenie

Podsumowując: W moim eksperymencie zdecydowanie najlepsze rezultaty osiągnął klasyfikator KNN.

Marne wyniki niestety osiągnął zarówno klasyfikator DecisionTree jak i sieć MLP.

W przypadku DecisionTree w moim rozumieniu największą trudnością jest stworzenie reguł, które w przypadku cen pojazdów mogą nie mieć większego sensu bez ogromnego zbioru danych, który po kilku latach stanie się wręcz bezużyteczny ze względu na warunki rynkowe.

Pierwszym przykładem przychodzącym mi na myśl może być taki samochód jak Porsche 911, którego podstawowy wariant może być kilka-kilkanaście razy tańszy niż najmocniejsza i najlepiej wyposażona wersja.

Na pierwszy rzut oka mogę stwierdzić, iż tokenizacja opisu mogłaby przynieść dobre rezultaty, gdyż stamtąd można by uzyskać takie informacje jak:

- czy sprzedający zajmuje się handlem zawodowo
- jaka jest wersja wyposażenia pojazdu
- czy samochód był naprawiany lub serwisowany

Podejrzewam, że obydwa te klasyfikatory osiągnęły, by lepsze wyniki w wersji regresywnej, bez podziału na kategorie cenowe.